

SCIDEX

AI Research Data Extraction for Systematic Review

Milestone 1: Investor Package

Bộ hồ sơ đánh giá và giới thiệu sản phẩm SaaS ứng dụng AI trong nghiên cứu học thuật, hỗ trợ quy trình trích xuất dữ liệu tự động có dẫn chứng và quy trình kiểm chứng con người (HITL).

Twitter Pitch (Thông điệp siêu ngắn gọn)

"Không còn cảnh mệt mỏi sao chép số liệu từ PDF nghiên cứu khoa học sang Excel. SCIDEX tự động parse văn bản, trích xuất cỡ mẫu, p-value, kết quả và đối chiếu trực tiếp với quote/số trang gốc. An toàn tuyệt đối khỏi ảo tưởng AI, tiết kiệm 95% thời gian."

NGƯỜI THỰC HIỆN (PRODUCT OWNER)
Vũ Tuấn Phương (MSSV: 2A202600772)

MÃ DỰ ÁN (PROJECT ID)
AI20K-C2-RES-09

CHƯƠNG TRÌNH & KHÓA
AI Practitioner Build Cohort 2

THỜI GIAN HOÀN THIỆN
Tháng 07 năm 2026 (Draft v3.0)

Pitch Memo (Bản Tóm Tắt Dự Án)

Hệ thống AI đột phá giúp giải quyết điểm nghẽn lớn nhất trong quy trình nghiên cứu học thuật và y dược.

1. Bối cảnh & Cơ hội thị trường

Quy trình tổng quan tài liệu có hệ thống (Systematic Review) và phân tích gộp (Meta-Analysis) là những bước bắt buộc trong nghiên cứu y học, dược phẩm và khoa học xã hội. Để thực hiện, nhóm nghiên cứu phải tải về hàng trăm tệp PDF bài báo, dành hàng tháng đọc quét thủ công để nhặt ra các trường số liệu cốt lõi: cỡ mẫu (sample size), phương pháp, p-value, odds ratio. Đây là quy trình hành chính thô sơ, lãng phí chất xám và cực kỳ dễ xảy ra sai sót dữ liệu.

2. Giải pháp SCIDEX

SCIDEX thiết lập một workflow AI có kiểm soát giúp tự động hóa quá trình trích xuất số liệu từ tệp PDF phi cấu trúc sang bảng dữ liệu có cấu trúc. Khác biệt cốt lõi của SCIDEX là tính kiểm chứng tuyệt đối thông qua 3 lớp bảo vệ:

- Semantic Anchoring (Neo ngữ nghĩa):** Mọi giá trị AI trích xuất bắt buộc phải đi kèm với đoạn trích dẫn (raw quote) và số trang cụ thể trong PDF gốc để người dùng đối chiếu tức thời.
- Missing & Conflict Detection:** Tự động cảnh báo khi thiếu thông tin quan trọng hoặc phát hiện các mâu thuẫn số liệu (ví dụ: abstract ghi cỡ mẫu một đằng, kết quả ghi một nẻo).
- Human Verification Guardrail (HITL):** Con người đóng vai trò duyệt cuối cùng. Trạng thái kiểm duyệt (Verified) được lưu vết rõ ràng và giữ nguyên khi chạy lại AI.

Giá trị mang lại cho khách hàng:

Năng suất gia tăng vượt bậc: Thời gian lập bảng so sánh dữ liệu 5 bài báo khoa học dài 100 trang giảm từ **4 tiếng xuống dưới 10 phút**. Sai sót số liệu được triệt tiêu hoàn toàn nhờ cơ chế đối chiếu dẫn chứng trực quan.

Market Analysis (Phân Tích Thị Trường)

1. Quy mô thị trường (Market Size)

Quy mô thị trường toàn cầu được định vị dựa trên số lượng các phòng nghiên cứu, trường đại học và ngân sách chi tiêu cho R&D y dược/học thuật:

TAM (Total Addressable Market)

\$4.2 Tỷ USD

Toàn bộ thị trường phần mềm hỗ trợ nghiên cứu khoa học và công cụ y tế số trên thế giới.

SAM (Serviceable Addressable Market)

\$850 Triệu USD

Thị trường các trường đại học, tổ chức lâm sàng và công ty R&D được phẩm có nhu cầu trích xuất dữ liệu.

SOM (Serviceable Obtainable Market) - Mục tiêu thiết thực trong 3 năm

\$45 Triệu USD

Chiếm 5% thị phần SAM bằng cách tập trung tiếp cận các nhóm nghiên cứu lớn tại Châu Á - Thái Bình Dương và các trường đại học quốc tế thông qua chiến lược Product-Led Growth (PLG).

2. Định vị cạnh tranh (Competitive Benchmarking)

SCIDEX giải quyết trực tiếp điểm yếu lớn nhất của các đối thủ cạnh tranh bằng cách đặt việc kiểm chứng dữ liệu học thuật làm trung tâm sản phẩm:

TIÊU CHÍ SO SÁNH	SCIDEX (CHÚNG TA)	ELICIT.COM	SCISPACE	CONSENSUS
Trích xuất Schema tùy biến	Cực tốt (Dynamic)	Có (Tốt)	Hạn chế	Không hỗ trợ
Dẫn chứng nguồn gốc (Quote)	Chi tiết tọa độ trang	Chỉ hiển thị text thô	Tự tra cứu	Chỉ trích xuất câu
Audit Log & HITL Guardrail	Có lưu vết đầy đủ	Không lưu lịch sử	Không có	Không có
Cảnh báo Conflict / Missing	Tự động (LLM Auditor)	Không hỗ trợ	Không hỗ trợ	Không hỗ trợ
Chi phí vận hành (Token Cost)	Rất thấp (Grobid local)	Cao (RAG mù)	Trung bình	Cao

Product Requirements Document (PRD) — Khách Hàng & Nỗi Đau

1. Đối tượng người dùng mục tiêu (Target Persona)

Nghiên cứu sinh & Bác sĩ Lâm sàng

Lực lượng chính trực tiếp làm nghiên cứu.

- Cần bóc tách hàng trăm bài báo để viết phần Literature Review trong luận án hoặc báo cáo lâm sàng.
- Đòi hỏi dữ liệu trích xuất chính xác để tránh kết luận sai lệch ảnh hưởng uy tín học thuật.

Giảng viên & Trưởng Lab R&D

Người kiểm duyệt và định hướng nghiên cứu.

- Phải kiểm tra lại bảng so sánh do học viên/nhân viên chuẩn bị trước khi gửi duyệt hoặc xuất bản.
- Đòi hỏi cơ chế truy vết (audit trail) nhanh chóng để xem nguồn gốc của từng số liệu trong bảng.

2. Điểm nghẽn cốt lõi cần giải quyết (Pain Points)

Quy trình nghiên cứu hiện nay đang chịu tổn thất lớn về thời gian và chất lượng dữ liệu do 4 nỗi đau lớn sau:

Nỗi đau 1: Quá tải đọc hiểu & Sao chép thủ công

Một bài báo y dược dài 15-30 trang. Để lấy cỡ mẫu hay chỉ số p-value, người dùng phải đọc quét từ đầu đến cuối. Khi số lượng tài liệu lên tới hàng chục, việc copy-paste thủ công gây kiệt sức và mất thời gian vô ích.

Nỗi đau 2: Dữ liệu ẩn và khóa trong bảng biểu (Tables) phức tạp

Hầu hết kết quả định lượng được hiển thị dưới dạng bảng ảnh hoặc định dạng PDF khóa. AI thông thường chỉ đọc text thô sẽ bỏ sót hoặc làm méo mó cấu trúc dữ liệu bảng biểu, dẫn đến nhập sai số liệu thập phân.

Nỗi đau 3: Sự ảo tưởng của AI (Hallucination) và mất lòng tin

Các mô hình ngôn ngữ lớn (LLM) nếu không được kiểm soát chặt chẽ sẽ tự động bịa ra số liệu hoặc đoán các giá trị thiếu. Trong y tế và dược phẩm, chỉ một sai lệch 0.01 p-value có thể biến một nghiên cứu vô giá trị thành phát kiến giả.

Nỗi đau 4: Dữ liệu thiếu (Missing) hoặc mâu thuẫn nội bộ không được gắn cờ

Nhiều bài viết công bố số liệu mâu thuẫn giữa tóm tắt (Abstract) và báo cáo chi tiết bên trong. Hiện tại không có công cụ nào tự động phát hiện các bất nhất này, để lại rủi ro lớn cho phân tích tổng hợp (Meta-Analysis).

Product Requirements Document (PRD) — Giải Pháp & Luồng Nghiệp Vụ

1. Giải pháp tính năng cốt lõi (Functional Solutions)

Để giải quyết triệt để các nỗi đau trên, SCIDEX MVP triển khai các tính năng bắt buộc sau:

- PDF Ingestion & Local Chunking (F-004):** Sử dụng parser chuyên dụng để tách PDF thành các đoạn văn bản sạch, giữ nguyên cấu trúc số trang và tọa độ dòng.
- Dynamic Extraction Template (F-005):** Người dùng tự định cấu trúc cột (ví dụ: *Sample Size, p-value*). Mỗi trường có hướng dẫn chi tiết dành riêng cho LLM.
- Controlled AI Extraction (F-006):** RAG thu hẹp ngữ cảnh kết hợp với Structured Output (JSON Schema) để đảm bảo LLM trả về đúng định dạng yêu cầu, tự động điền '[Not Found]' nếu không tìm thấy dữ liệu.
- Semantic Anchoring Evidence (F-007):** Giao diện hai màn hình (Split View). Khi bấm vào một ô dữ liệu, cửa sổ bên cạnh hiển thị trang PDF gốc và highlight đoạn văn bản chứng minh.
- Conflict & Quality Warnings (F-009):** Tự động gắn nhãn đỏ và cảnh báo các mâu thuẫn số liệu hoặc trường bắt buộc bị thiếu trong Panel Cảnh báo.

2. Luồng nghiệp vụ người dùng (User Experience Flow)

Thiết kế luồng tương tác đơn giản, rõ ràng, đảm bảo con người kiểm soát dữ liệu cuối cùng trước khi xuất:

Quy trình tương tác E2E:

- Tạo dự án:** Người dùng đăng nhập, tạo Project nghiên cứu mới (ví dụ: "Review tác dụng của Caffeine đối với trí nhớ"). Hệ thống tự tạo template với 6 cột cơ bản.
- Upload tài liệu:** Kéo thả tối đa 5 file PDF bài báo khoa học. Hệ thống tự động parse ngầm và cập nhật trạng thái 'parsed'.
- Chạy trích xuất:** Nhấp "Run Extraction". Celery worker chạy ngầm, LLM trích xuất số liệu và ghi nhận dẫn chứng vào bảng.
- Kiểm duyệt & Hiệu chỉnh:** Nhấp vào ô dữ liệu để xem dẫn chứng chứng minh. Người dùng có thể sửa đổi trực tiếp các ô bị AI điền sai hoặc xử lý các cảnh báo mâu thuẫn (Conflict Warning).
- Xác nhận & Xuất bản:** Nhấp "Verify" để khóa dữ liệu sạch. Tiến hành xuất báo cáo Excel/CSV chỉ chứa các dữ liệu đã xác thực ('only_verified=true').

Financial Model (Mô Hình Tài Chính 3 Năm)

Kế hoạch doanh thu dựa trên mô hình đăng ký tài khoản (SaaS Subscription) và tối ưu hóa hạ tầng.

1. Phân cấp gói dịch vụ (Subscription Pricing Tiers)

Doanh thu của SCIDEX được tạo ra từ 3 gói dịch vụ trả phí chính hướng đến khách hàng cá nhân và tổ chức nghiên cứu:

GÓI DỊCH VỤ	PHÍ DỊCH VỤ / THÁNG	GIỚI HẠN TÀI NGUYÊN / THÁNG	TÍNH NĂNG NỔI BẬT
Free Tier	Miễn phí (\$0)	3 projects, 10 papers, 50 cells	Trích xuất thô, Xuất CSV kèm quảng cáo
Pro Tier	\$19 USD (Cá nhân)	20 projects, 50 papers, 1,000 cells	Không quảng cáo, Custom API Key, Xuất Excel
Team Tier	\$49 USD (Nhóm lab)	100 projects, 200 papers, 10,000 cells	Chia sẻ dự án (5 thành viên), Ưu tiên xử lý
Enterprise	Custom (Trung bình \$299)	Không giới hạn tài nguyên	Private Server, Phân tích Meta-Analysis nâng cao

2. Dự phóng tài chính 3 năm (3-Year Financial Projections)

Dự báo tài chính dựa trên tốc độ tăng trưởng người dùng đăng ký trả phí và tối ưu hóa chi phí token LLM nhờ parser nội bộ:

CHỈ SỐ TÀI CHÍNH	NĂM 1 (KHỞI TẠO)	NĂM 2 (TĂNG TRƯỞNG)	NĂM 3 (TĂNG TỐC)
Tổng người dùng hoạt động (MAU)	5,000	25,000	90,000
Số người dùng trả phí (Pro + Team)	200	1,000	4,000
Doanh thu định kỳ năm (ARR)	\$60,000 USD	\$300,000 USD	\$1,200,000 USD
Chi phí API LLM & Cloud Server (15%)	\$9,000 USD	\$45,000 USD	\$180,000 USD
Chi phí Marketing & Bán hàng (25%)	\$15,000 USD	\$75,000 USD	\$300,000 USD
Chi phí Vận hành & Nhân sự (40%)	\$24,000 USD	\$120,000 USD	\$480,000 USD
Lợi nhuận ròng trước thuế (NP)	\$12,000 USD	\$60,000 USD	\$240,000 USD
Biên lợi nhuận gộp (Gross Margin)	85%	85%	85%

Unit Economics (Chỉ Số Kinh Tế Đơn Vị)

1. Phân tích doanh thu và chi phí trên từng người dùng (Unit Level)

Để chứng minh tính bền vững của mô hình kinh doanh SaaS, chúng ta phân tích các chỉ số tài chính dựa trên một tài khoản Pro trung bình (giá **\$19 USD/tháng**, giả định sử dụng hết quota 1,000 cells/tháng):

Chi phí biến đổi (Cost of Goods Sold - COGS):

- Chi phí token LLM (GPT-4o-mini):** Trung bình \$1.50 USD cho 1,000 cells trích xuất (được tối ưu hóa bằng cách gọi ngữ cảnh hẹp thay vì đẩy toàn bộ PDF dài vào LLM).
- Chi phí lưu trữ Cloud & Server:** \$1.35 USD (lưu trữ tệp PDF trên R2, cơ sở dữ liệu Postgres trên Supabase).
- Tổng COGS:** \$2.85 USD / khách hàng / tháng.

Biên lợi nhuận gộp (Gross Margin %):

Doanh thu thuần trừ đi COGS:

85% (\$16.15 USD)

Biên lợi nhuận gộp cực cao, đặc trưng của mô hình phần mềm SaaS được tối ưu hóa cấu trúc dữ liệu RAG.

2. Các chỉ số sức khỏe tài chính cốt lõi (Core Business Metrics)

ARPU (Doanh thu trung bình trên mỗi user)

\$25 USD / tháng

Tính toán trọng số dựa trên tỷ lệ phân bổ người dùng đăng ký: 75% gói Pro (\$19), 20% gói Team (\$49), và 5% gói Enterprise (trung bình \$299).

CAC (Chi phí thu hút một khách hàng trả phí)

\$60 USD

Thu hút người dùng thông qua các kênh quảng cáo hướng đối tượng (Google/Facebook Ads nhắm vào giới học thuật), SEO từ khóa nghiên cứu khoa học, và tài trợ tại các hội thảo y dược.

LTV (Lifetime Value - Giá trị vòng đời)

\$500 USD

Dựa trên tỷ lệ khách hàng hủy dịch vụ (Churn Rate) là **5% mỗi tháng**.
 $LTV = ARPU / Churn Rate = \$25 / 0.05 = \$500$.

Tỷ lệ LTV / CAC & Thời gian hoàn vốn

8.3x | 2.8 Tháng

Tỷ số LTV/CAC đạt 8.3 lần, vượt xa ngưỡng an toàn tiêu chuẩn của ngành SaaS (>3x). Thời gian hoàn vốn thu hồi CAC chỉ mất 2.8 tháng.

Roadmap & OKRs (Lộ Trình & Quản Trị Mục Tiêu)

1. Lộ trình phát triển Now / Next / Later (1 Trang)

Lộ trình phát triển được tinh gọn để ưu tiên chất lượng trích xuất trước khi mở rộng dịch vụ hỗ trợ:



NOW (Core MVP)

- Upload PDF trực tiếp lên Cloud R2.
- Parse PDF bất đồng bộ thành chunks bằng PyMuPDF và Grobid local.
- Thiết lập bảng kết quả có liên kết dẫn chứng (Semantic Anchoring).
- Chỉnh sửa và Verify cell (HITL).
- Xuất file CSV báo cáo.



NEXT (Mở rộng)

- API Search học thuật trực tuyến (Semantic Scholar & OpenAlex).
- AI Conflict Auditor tự động phát hiện số liệu mâu thuẫn.
- Tự động bôi màu highlight dẫn chứng trực tiếp trên PDF canvas.
- Xuất file Excel/XLSX định dạng.



LATER (Dài hạn)

Trợ lý đa tác vụ dựa trên Agentic AI và môi trường cộng tác làm việc nhóm:

- Multi-agent Chat Assistant (LangGraph).
- Tích hợp PDF OCR Fallback Service.
- Môi trường cộng tác nhóm (Real-time).
- Vẽ biểu đồ phân tích Meta-Analysis.

2. Quản trị mục tiêu Q3/2026 (Strategic OKRs)

Objective: Đưa SCIDEX thành công cụ trích xuất dữ liệu bài báo học thuật tiêu chuẩn, tăng năng suất nghiên cứu và đảm bảo dữ liệu chính xác tuyệt đối.

- KR1 Giảm 95.8% thời gian trích xuất:** Rút ngắn thời gian lập bảng so sánh dữ liệu cho 5 bài báo (100 trang PDF) từ 4 giờ (thủ công) xuống dưới 10 phút.
- KR2 100% Citation Coverage:** Đảm bảo 100% số ô kết quả được AI điền vào bảng trích xuất đều phải đính kèm dẫn chứng cụ thể từ tệp PDF gốc để đối chiếu, triệt tiêu hallucination.
- KR3 Tỷ lệ Verified Rate > 80%:** Đảm bảo hơn 80% số ô dữ liệu xuất ra báo cáo (Export) đã được người dùng rà soát và nhấn xác thực (Verify) trên giao diện.

Dependency Map & Critical Path (Sơ Đồ Phụ Thuộc & Đường Găng)

1. Điểm phụ thuộc & Kịch bản dự phòng (Plan B)

ĐIỂM PHỤ THUỘC	RỦI RO CHÍNH GẶP PHẢI	KỊCH BẢN DỰ PHÒNG (PLAN B)
Search API (Semantic Scholar)	Rate limit, API bị lỗi downtime đột ngột, thiếu thông tin DOI.	Cho phép Upload PDF thủ công , lưu metadata thô và cho người dùng sửa.
LLM Provider API (OpenAI/Anthropic)	Độ trễ cao trong giờ cao điểm, hết quota API, chi phí token cao.	Cơ chế Dual-routing (chuyển sang GPT-4o-mini), cho cấu hình Custom API Key .
PDF Parser (Grobid running local)	Dịch vụ bị treo khi parse tệp quá dài, parse lỗi định dạng bảng biểu.	Celery task tự động timeout sau 60s và chuyển sang parse text thô , nhập thủ công.

2. Đường găng dự án trong 4 tuần (Critical Path Gantt Chart)

Các nhiệm vụ nối tiếp trên đường găng quyết định tiến độ ra mắt MVP của SCIDEX:

[Tuần 1: Thiết kế & DB] → Thiết kế Database Schema (3 ngày)
▼
[Tuần 1-2: Parser] → PDF Ingestion & Parse Worker (5 ngày)
▼
[Tuần 2-3: Extraction] → Structured AI Extraction Engine (6 ngày)
▼
[Tuần 3: Frontend] → Evidence Table UI & Verification View (6 ngày)
▼
[Tuần 4: Release] → Export Engine & E2E Testing (7 ngày) → Release MVP!

🔗 Phụ Lục Tài Liệu Kèm Theo (Mandatory Appendix Links)

👉 Bảng tính mô hình tài chính chi tiết (Excel):

https://github.com/tuanphilip/SCIDEX/blob/main/docs/financial_model_v1.0.xlsx

(Tài liệu tính toán chi tiết mô hình tài chính, chi phí token và dự phóng người dùng)

👉 Tài liệu Đặc tả Yêu cầu Sản phẩm (Full PRD):

<https://github.com/tuanphilip/SCIDEX/blob/main/docs/02-prd.md>

(Tài liệu đặc tả chi tiết 12 tính năng của sản phẩm và sơ đồ cơ sở dữ liệu)